

Множествени тестове

Изготвена от Надежда Францева
специалност : Изкуствен Интелект

Съдържание

1. Преглед на тестването на хипотези
 1. Тестването на хипотези
 2. Грешки от тип I и тип II
2. Предизвикателства на многократното тестване
3. Степен на семейни грешки
 1. Какво е степен на семейни грешки ?
 2. Подходи за контролиране на степента на семейни грешки
 1. Методът на Бонферони
 2. Процедурата на Холм за понижаване на степента
4. Степен на фалшиви открития
 1. Интуиция за степента на фалшиви открития
 2. Процедурата на Бенджамини-Хохберг
5. Подход за повторно вземане на проби към p -стойности и коефициенти на фалшиви открития
 1. Подход за повторно вземане на проби към p -стойността
 2. Подход за повторно вземане на проби към коефициента на фалшиви открития
 3. Кога са полезни подходите за повторно вземане на проби ?

1. Преглед на тестването на хипотези

- Тестването на хипотези

- Стъпка 1: Дефинираме нулевата и алтернативната хипотеза
- Стъпка 2: Конструираме тестовата статистика
- Стъпка 3: Изчисляваме р-стойността
- Стъпка 4: Решаваме дали да отхвърлим нулевата хипотеза

$$T = \frac{\hat{\mu}_t - \hat{\mu}_c}{s \sqrt{\frac{1}{n_t} + \frac{1}{n_c}}}$$

$$\hat{\mu}_t = \frac{1}{n_t} \sum_{i=1}^{n_t} x_i^t$$

$$\hat{\mu}_c = \frac{1}{n_c} \sum_{i=1}^{n_c} x_i^c$$

$$s = \sqrt{\frac{(n_t - 1)s_t^2 + (n_c - 1)s_c^2}{n_t + n_c - 2}}$$

1. Преглед на тестването на хипотези

- Грешки от тип I и тип II

		Truth	
		H_0	H_a
Decision	Reject H_0	Type I Error	Correct
	Do Not Reject H_0	Correct	Type II Error

2. Предизвикателства на многократното тестване

- Същността на проблема: отхвърлянето на нулева хипотеза, ако p -стойността е под α , контролира вероятността за фалшиво отхвърляне на тази нулева хипотеза на ниво α . Въпреки това, ако направим това за m нулеви хипотези, тогава шансът за грешно отхвърляне на поне една от m нулеви хипотези е доста по-висок!

3. Степен на семейни грешки

- Какво е степен на семейни грешки ?

	H_0 is True	H_0 is False	Total
Reject H_0	V	S	R
Do Not Reject H_0	U	W	$m - R$
Total	m_0	$m - m_0$	m

$$\text{FWER} = \Pr(V \geq 1)$$

$$\text{FWER}(\alpha) = 1 - \prod_{j=1}^m (1 - \alpha) = 1 - (1 - \alpha)^m$$

3. Степен на семейни грешки

- Подходи за контролиране на степента на семейни грешки

- Методът на Бонферони

- Процедурата на Холм

за понижаване на степента

$$\begin{aligned}\text{FWER} &= \Pr(\text{falsely reject at least one null hypothesis}) \\ &= \Pr(\cup_{j=1}^m A_j) \\ &\leq \sum_{j=1}^m \Pr(A_j).\end{aligned}$$

$$\text{FWER}(\alpha/m) \leq m \times \frac{\alpha}{m} = \alpha$$

3. Степен на семейни грешки

- Подходи за контролиране на степента на семейни грешки

- Методът на Бонферони
- Процедурата на Холм
за понижаване на степента

1. Specify α , the level at which to control the FWER.
2. Compute p -values, $p_1, \dots, p_m$, for the m null hypotheses $H_{01}, \dots, H_{0m}$.
3. Order the m p -values so that $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$.

4. Define

$$L = \min \left\{ j : p_{(j)} > \frac{\alpha}{m + 1 - j} \right\}.$$

5. Reject all null hypotheses H_{0j} for which $p_j < p_{(L)}$.

4. Степен на фалшиви открития

- Интуиция за степента на фалшиви открития

4. Степен на фалшиви открития

- Процедурата на Бенджамини-Хохберг

1. Specify q , the level at which to control the FDR.
2. Compute p -values, $p_1, \dots, p_m$, for the m null hypotheses $H_{01}, \dots, H_{0m}$.
3. Order the m p -values so that $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$.

4. Define

$$L = \max\{j : p_{(j)} < qj/m\}.$$

5. Reject all null hypotheses H_{0j} for which $p_j \leq p_{(L)}$.

5. Подход за повторно вземане на проби към р-стойности и коефициенти на фалшиви открития

- Подход за повторно вземане на проби към р-стойността

$$p\text{-value} = \frac{\sum_{b=1}^B 1_{(|T^{*b}| \geq |T|)}}{B},$$

1. Compute T , defined in (13.11), on the original data $x_1, \dots, x_{n_X}$ and $y_1, \dots, y_{n_Y}$.
2. For $b = 1, \dots, B$, where B is a large number (e.g. $B = 10,000$):
 - (a) Permute the $n_X + n_Y$ observations at random. Call the first n_X permuted observations $x_1^*, \dots, x_{n_X}^*$, and call the remaining n_Y observations $y_1^*, \dots, y_{n_Y}^*$.
 - (b) Compute (13.11) on the permuted data $x_1^*, \dots, x_{n_X}^*$ and $y_1^*, \dots, y_{n_Y}^*$, and call the result T^{*b} .
3. The p -value is given by $\frac{\sum_{b=1}^B 1_{(|T^{*b}| \geq |T|)}}{B}$.

5. Подход за повторно вземане на проби към р-стойности и коефициенти на фалшиви открития

- Подход за повторно вземане на проби към коефициента на фалшиви открития

$$\text{FDR} = E \left(\frac{V}{R} \right) \approx \frac{E(V)}{R}.$$

$$R = \sum_{j=1}^m 1_{(|T_j| \geq c)}.$$

$$p_j = \frac{\sum_{j'=1}^m \sum_{b=1}^B 1_{(|T_{j'}^{*b}| \geq |T_j|)}}{Bm}$$

1. Select a threshold c , where $c > 0$.
2. For $j = 1, \dots, m$:
 - (a) Compute $T^{(j)}$, the two-sample t -statistic (13.11) for the null hypothesis H_{0j} on the basis of the original data, $x_1^{(j)}, \dots, x_{n_X}^{(j)}$ and $y_1^{(j)}, \dots, y_{n_Y}^{(j)}$.
 - (b) For $b = 1, \dots, B$, where B is a large number (e.g. $B = 10,000$):
 - i. Permute the $n_X + n_Y$ observations at random. Call the first n_X observations $x_1^{*(j)}, \dots, x_{n_X}^{*(j)}$, and call the remaining observations $y_1^{*(j)}, \dots, y_{n_Y}^{*(j)}$.
 - ii. Compute (13.11) on the permuted data $x_1^{*(j)}, \dots, x_{n_X}^{*(j)}$ and $y_1^{*(j)}, \dots, y_{n_Y}^{*(j)}$, and call the result $T^{(j),*b}$.
3. Compute $R = \sum_{j=1}^m 1_{(|T^{(j)}| \geq c)}$.
4. Compute $\hat{V} = \frac{\sum_{b=1}^B \sum_{j=1}^m 1_{(|T^{(j),*b}| \geq c)}}{B}$.
5. The estimated FDR associated with the threshold c is $\hat{V}/R$.

5. Подход за повторно вземане на проби към р-стойности и коефициенти на фалшиви открития

- Кога са полезни подходите за повторно вземане на проби ?
 - 1. Може би не е налично теоретично нулево разпределение. Това може да е случай, ако тествате необичайна нулева хипотеза H_0 или използвате необичайна тестова статистика T .
 - 2. Може би е налично теоретично нулево разпределение, но предположенията, необходими за неговата валидност, не са валидни. Например t -статистиката за две извадки следва $t_{nX+nY-2}$ разпределение само ако наблюденията са нормално разпределени. Освен това следва $N(0, 1)$ разпределение само ако nX и nY са доста големи. Ако данните са ненормално разпределени и nX и nY са малки, тогава р-стойности, които са полезни на теоретичното нулево разпределение няма да са валидни (т.е. те няма да контролират правилно грешката от тип I).

Благодаря за вниманието

Проект

**Математически основи на машинното
самообучение и изкуствения интелект,
зимен семестър 2023/2024**



Име: Надежда Францева

ФН: 8МІ3400357

Специалност: Изкуствен Интелект

Множествени тестове

Множествените тестове се използват за проверка на хипотези, когато имаме множество сравнения между групи. В съвременните условия често се сблъскваме с огромни количества данни и следователно може да поискаме да тестваме много нулеви хипотези. Например, вместо просто да тестваме H_0 , може да искаме да тестваме m нулеви хипотези: $H_{01}, \dots, H_{0m}$, където H_{0j} : очакваната стойност на j -тия маркер сред контролната група да е равен на очакваната стойност на j -ти маркер сред неконтролната група. Когато провеждаме множество тестове, трябва да бъдем много внимателни за това как интерпретираме резултатите, за да се избегнем погрешно отхвърляне на твърде много нулеви хипотези.

1. Преглед на тестването на хипотези

Тестовите за хипотези предоставят строга статистическа рамка за отговаряне на прости въпроси „да или не“ относно данни. Следва кратък преглед на стъпките, включени в тестването на хипотези и различните видове грешки, които може да възникнат при проверка на хипотези.

1.1. Тестването на хипотези

Провеждането на тест за хипотеза обикновено протича в четири стъпки. Първо, дефинираме нулевата и алтернативната хипотеза. След това изграждаме тестова статистика, което обобщава силата на доказателствата срещу нулевата хипотеза. След това изчисляваме p -стойност, която определя количествено вероятността да сме получили сравнима или по-екстремна стойност на тестовата статистика при нулевата хипотеза. Накрая, въз основа на p -стойността, решаваме дали да отхвърлим нулевата хипотеза. Сега обсъждаме накратко всяка от тези стъпки на свой ред.

1.1.1. Стъпка 1: Дефинираме нулевата и алтернативната хипотеза

При тестване на хипотези ние разделяме света на две възможности: нулевата хипотеза и алтернативната хипотеза. Нулевата хипотеза е скучна като конструкция: може и да е вярна, но може да се надяваме, че нашите данни ще ни кажат друго. Алтернативната хипотеза, обозначена като H_a , представлява нещо различно и неочаквани. Обикновено алтернативната хипотеза просто приема като факт, че нулевата хипотеза не е валидна: ако нулевата хипотеза твърди, че няма разлика между A и B , тогава алтернативната хипотеза твърди, че има разлика между A и B . Важно е да се отбележи че третирането на H_0 и H_a е асиметрично. H_0 се третира като състояние по подразбиране на света и ние се фокусираме върху използването на данни за отхвърляне на H_0 . Ако отхвърлим H_0 , това предоставя доказателство в полза на H_a . Можем да мислим за отхвърляне

на H_0 като за откритие относно нашите данни: а именно, ние откриваме, че H_0 не е валидно! Обратно, ако не успеем да отхвърлим H_0 , тогава нашите констатации са по-неясни: няма да знаем дали не сме успели да отхвърлим H_0 , защото размерът на нашата извадка е твърде малък (в който случай тестването на H_0 отново върху по-голям или по-качествен набор от данни може водят до отхвърляне), или дали не сме успели да отхвърлим H_0 , защото H_0 наистина важи.

1.1.2. Стъпка 2: Конструираме тестовата статистика

След това искаме да използваме нашите данни, за да намерим доказателства за или против нулевата хипотеза. За да направим това, трябва да изчислим тестова статистика, тестова статистика, означена с T , която обобщава степента, до която нашите данни са в съответствие с H_0 . Начинът, по който конструираме T зависи от естеството на нулевата хипотеза, която тестваме. За да направим нещата конкретни, нека

$x_1^t, \dots, x_{n_t}^t$ означава измерванията за n_t обекти в неконтролната групата и нека $x_1^c, \dots, x_{n_c}^c$ означават измерванията за n_c обекти в контролната група и $\mu_t = E(X_t)$, $\mu_c = E(X_c)$. За да тестваме $H_0 : \mu_t = \mu_c$, ние използваме t -статистика с две извадки, дефинирана като

$$T = \frac{\hat{\mu}_t - \hat{\mu}_c}{s \sqrt{\frac{1}{n_t} + \frac{1}{n_c}}}, \quad \hat{\mu}_t = \frac{1}{n_t} \sum_{i=1}^{n_t} x_i^t \quad \text{и}$$

$$\hat{\mu}_c = \frac{1}{n_c} \sum_{i=1}^{n_c} x_i^c \quad \text{и}$$

$$s = \sqrt{\frac{(n_t - 1)s_t^2 + (n_c - 1)s_c^2}{n_t + n_c - 2}}$$

е оценка на обединеното

стандартно отклонение на двете проби. Тук s_t^2 и s_c^2 са безпристрастни оценки на дисперсията на метриката в контролната и неконтролната групи, съответно. Ако T има голяма (абсолютна) стойност, то това осигурява доказателство срещу H_0 : $\mu_t = \mu_c$ и следователно доказателство в подкрепа на H_a : $\mu_t \neq \mu_c$.

1.1.3. Стъпка 3: Изчисляваме p -стойността

В предишния раздел отбелязахме, че голяма (абсолютна) стойност на t -статистика за две проби предоставя доказателство срещу H_0 . Това повдига

въпроса: колко голямо е голямо? С други думи, колко доказателства срещу H_0 се осигуряват от дадена стойност на тестовата статистика?

Понятието p -стойност ни дава начин да формализираме, както и p -стойността да отговори на този въпрос. P -стойността се дефинира като вероятността за наблюдение на тестова статистика, равна или по-екстремна от наблюдаваната статистика, при допускането, че H_0 всъщност е вярно. Следователно, малка p -стойност предоставя доказателство срещу H_0 . Като цяло, най-често използваните тестови статистики следват добре известно статистическо разпределение при нулевата хипотеза - като нормално разпределение, t -разпределение, χ^2 -разпределение или F -разпределение - при условие че размерът на извадката е достатъчно голям и някои други предположения са валидни. Обикновено функцията R , която се използва за изчисляване на тестова статистика, ще използва това нулево разпределение, за да изведе p -стойност.

Единственото правилно тълкуване на p -стойността е като част от времето, през което бихме очаквали да видим такава екстремна стойност на тестовата статистика, ако повторим експеримента много пъти, при условие, че H_0 държи. В Стъпка 2 изчислихме тестова статистика и отбелязахме, че голяма (абсолютна) стойност на тестовата статистика предоставя доказателство срещу H_0 . В Стъпка 3 тестовата статистика беше преобразувана в p -стойност, с малки p -стойности, предоставящи доказателство срещу H_0 . Какво тогава постигнахме, като преобразувахме тестовата статистика от Стъпка 2 в p -стойност в Стъпка 3? P -стойността ни позволява да трансформираме нашата тестова статистика, която се измерва по някаква произволна и неподлежаща на интерпретация скала, в число между 0 и 1, което може да бъде по-лесно интерпретирано.

1.1.4. Стъпка 4: Решаваме дали да отхвърлим нулевата хипотеза

След като сме изчислили p -стойност, съответстваща на H_0 , тя остава за да решим дали да отхвърлим или не H_0 . (Обикновено не говорим за „приемане“ на H_0 : вместо това говорим за „неуспешно отхвърляне“ на H_0 .) Малка p -стойност показва, че такава голяма стойност на тестовата статистика е малко вероятно да се появи при H_0 и по този начин предоставя доказателства срещу H_0 . Ако p -стойността е достатъчно малка, тогава ще искаме да отхвърлим H_0 (и следователно да направим „откритие“). Но колко малък е достатъчно малък, за да отхвърли H_0 ? Оказва се, че отговорът на този въпрос е много в очите на наблюдателя, или по-конкретно, на анализатора на данни. Колкото по-малка е p -стойността, толкова по-силни са доказателствата срещу H_0 . В някои полета е типично да се отхвърли H_0 , ако p -стойността е под 0,05; това означава, че ако H_0 е в сила, бихме очаквали да видим такава малка p -стойност не повече от 5% от времето. Въпреки това, в други области се изисква много по-голяма тежест на доказване.

1.2. Грешки от тип I и тип II

Ако нулевата хипотеза е валидна, тогава казваме, че това е истинска нулева хипотеза; истинска нулева хипотеза, в противен случай това е невярна нулева хипотеза. Разбира се, ние не знаем предварително дали H_0 е вярно или невярно: ето защо трябва да проведем тест на хипотеза! Следната таблица обобщава възможните сценарии, свързани с тестването на нулевата хипотеза H_0 :

		Truth	
		H_0	H_a
Decision	Reject H_0	Type I Error	Correct
	Do Not Reject H_0	Correct	Type II Error

След като се извърши проверката на хипотезата, редът на таблицата е известен (на базата на това дали сме отхвърлили или не H_0); за нас обаче е невъзможно да знаем в коя колона се намираме. Ако отхвърлим H_0 , когато H_0 е невярно (т.е. когато H_a е вярно), или ако не отхвърлим H_0 , когато е вярно, тогава сме стигнали до правилния резултат. Ако обаче погрешно отхвърлим H_0 , когато H_0 всъщност е вярно, тогава сме допуснали грешка от тип I. Процентът на грешка от тип I се определя като вероятността да се направи грешка от тип I, като се има предвид, че процентът α на грешка от тип I е валиден, т.е. вероятността за неправилно отхвърляне на H_0 . Като алтернатива, ако ние не отхвърляме H_0 , когато H_0 всъщност е невярно, тогава сме извършили грешка тип II. Силата на теста на хипотезата се дефинира като степента на вероятност за грешка от тип II да не се допусне грешка от тип II, като се има предвид, че H_a е в сила, т.е. вероятността за правилно отхвърляне на H_0 . В идеалния случай бихме искали нивата на грешки от тип I и тип II да са малки. Но на практика това е трудно постижимо! Обикновено има размяна на: можем да направим грешката от тип I малка, като отхвърлим само H_0 , ако сме съвсем сигурни, че не е валидна; това обаче ще доведе до увеличаване на Тип II грешка. Като алтернатива можем да направим грешката тип II малка, като отхвърлим H_0 при наличието дори на скромни доказателства, че не е валидно, но това ще доведе до голяма грешка от тип I. На практика ние обикновено разглеждаме грешките от тип I като по-сериозни от грешките от тип II, тъй като първите включват деклариране на научно откритие, което не е правилно. Следователно, когато извършваме тестване на хипотези, ние обикновено изискваме нисък процент грешки от тип I — например най-много $\alpha = 0,05$ — докато се опитваме да направим грешката от тип II малка (или, еквивалентно, мощността голяма). Оказва се, че има пряко съответствие между прага на p -стойността, който ни кара да отхвърлим H_0 , и процента на грешки от тип I. Като отхвърляме H_0 само когато p -стойността е под α , ние гарантираме, че процентът на грешки от тип I ще бъде по-малък или равен на α .

2. Предизвикателства на многократното тестване

Ако искаме да тестваме m нулеви хипотези: $H_{01}, \dots, H_{0m}$. Ще бъде ли подходящо просто да се отхвърлят всички нулеви хипотези, за които съответната p -стойност пада под (да кажем) 0,01? Казано по друг начин, ако отхвърлим всички нулеви хипотези, за които p -стойността пада под 0,01, тогава колко грешки от тип I трябва да очакваме да направим ?

Основното предизвикателство на множественото тестване е когато то тества огромен брой нулеви хипотези, ние сме длъжни да получим някои много малки p -стойности случайно. Ако вземем решение дали да отхвърлим всяка нулева хипотеза, без да вземем предвид факта, че сме извършили много голям брой тестове, тогава може да се окаже, че отхвърлим голям брой истински нулеви хипотези - тоест, да направим голям брой Грешки тип I.

Колко тежък е проблемът? От предишния раздел - ако отхвърлим една единствена нулева хипотеза, H_0 , ако нейната p -стойност е по-малка от, да речем, $\alpha = 0,01$, тогава има 1% шанс да направим грешно отхвърляне, ако H_0 всъщност е вярно. Сега какво ще стане, ако тестваме m нулеви хипотези, $H_{01}, \dots, H_{0m}$, всички от които са верни? Има 1% шанс за отхвърляне на всяка отделна нулева хипотеза; следователно очакваме да отхвърлим погрешно приблизително $0,01 \times m$ нулеви хипотези. Ако $m = 10\,000$, това означава, че очакваме случайно да отхвърлим погрешно 100 нулеви хипотези! Това са много грешки от тип I. Същността на проблема е следната: отхвърлянето на нулева хипотеза, ако p -стойността е под α , контролира вероятността за фалшиво отхвърляне на тази нулева хипотеза на ниво α . Въпреки това, ако направим това за m нулеви хипотези, тогава шансът за грешно отхвърляне на поне една от m нулеви хипотези е доста по-висок!

Ще проучим този проблем по-подробно и ще предложим решение за него в следващата точка.

3. Степен на семейни грешки

В тази точка ще обсъдим тестването на множество хипотези, като същевременно контролираме вероятността да направим поне една грешка от тип I.

3.1. Какво е степен на семейни грешки ?

Както казахме процентът на грешки от тип I е вероятността за отхвърляне на H_0 , ако H_0 е вярно. Степента на грешки по отношение на семейството (FWER) обобщава това понятие до процент на грешки по отношение на множеството на m нулеви хипотези, $H_{01}, \dots, H_{0m}$, и се дефинира като вероятността да се направи поне една грешка от тип I. За да изразим тази идея по-формално, разглеждаме следната таблица, която обобщава възможните резултати при извършване на m теста на хипотези:

	H_0 is True	H_0 is False	Total
Reject H_0	V	S	R
Do Not Reject H_0	U	W	$m - R$
Total	m_0	$m - m_0$	m

Тук V представлява броя на грешките от тип I (известни също като фалшиви положителни резултати или фалшиви открития), S броят на истинските положителни резултати, U броят на истинските отрицателни резултати и W броят на грешките от тип II (известни също като фалшиви отрицателни

результати). Тогава процентът на грешки по отношение на семейството се дава

$$\text{FWER} = \Pr(V \geq 1)$$

от

Стратегия за отхвърляне на всяка нулева хипотеза, за която р-стойността е под α (т.е. контролиране на грешка от тип I за всяка нулева хипотеза на ниво α) води до FWER от

$$\begin{aligned} \text{FWER}(\alpha) &= \\ &= 1 - \Pr(V = 0) = \\ &= 1 - \Pr(\text{do not falsely reject any null hypotheses}) = \\ &= 1 - \Pr\left(\bigcap_{j=1}^m \{\text{do not falsely reject } H_{0j}\}\right) \end{aligned}$$

От основната вероятност, ако две събития A и B са независими, тогава $\Pr(A \cap B) = \Pr(A) \Pr(B)$. Следователно, ако направим допълнителни доста силни предположения, че $\underline{m}$ тестовете са независими и че всички $\underline{m}$ нулеви хипотези са верни, тогава

$$\text{FWER}(\alpha) = 1 - \prod_{j=1}^m (1 - \alpha) = 1 - (1 - \alpha)^m$$

Следователно, ако тестваме само една нулева хипотеза, тогава

$$\text{FWER}(\alpha) = 1 - (1 - \alpha)^1 = \alpha$$

Така че процентът на грешки от тип I и FWER са равни. Въпреки това, ако извършим $m = 100$ независими теста, тогава $\text{FWER}(\alpha) = 1 - (1 - \alpha)^{100}$. Например, приемането на $\alpha = 0,05$ води до FWER от $1 - (1 - 0,05)^{100} = 0,994$. С други думи, на практика ни е гарантирано да направим поне една грешка от тип I!

Фигура 13.2 показва (13.5) за различни стойности на $\underline{m}$, броя на хипотезите и α , грешка от тип I. Виждаме, че настройката $\alpha = 0,05$ води до висока FWER дори за умерено $\underline{m}$. С $\alpha = 0,01$ можем да тестваме не повече от пет нулеви хипотези, преди FWER да надхвърли 0,05. Само за много малки стойности, като $\alpha = 0,001$, успяваме да осигурим малък FWER, поне за $\underline{m}$ със среден размер.

3.2. Подходи за контролиране на степента на семейни грешки

Контролирането на FWER на ниво α представлява много по-висока летва по отношение на доказателствата, необходими за отхвърляне на дадена нулева хипотеза, отколкото простото контролиране на грешката от тип I за всяка нулева хипотеза на ниво α .

3.2.1. Методът на Бонферони

Да предположим, че искаме да тестваме $H_{01}, \dots, H_{0m}$. Нека $\underline{A}_j$ обозначава събитието, при което правим грешка от тип I за j -тата нулева хипотеза, за $j = 1, \dots, m$. Тогава

$$\begin{aligned}
 \text{FWER} &= \Pr(\text{falsely reject at least one null hypothesis}) \\
 &= \Pr(\cup_{j=1}^m A_j) \\
 &\leq \sum_{j=1}^m \Pr(A_j).
 \end{aligned}$$

Неравенството е резултат от факта, че за всеки две събития А и В, $\Pr(A \cup B) \leq \Pr(A) + \Pr(B)$, независимо дали А и В са независима. Методът на Бонферони или корекцията на Бонферони задава праг за отхвърляне на всеки тест на хипотеза до α/m , така че $\Pr(A_j) \leq \alpha/m$. Уравнение предполага следното нещо:

$$\text{FWER}(\alpha/m) \leq m \times \frac{\alpha}{m} = \alpha$$

така че тази процедура контролира FWER на ниво α . Например, за да контролирате FWER на ниво 0.1, докато тествете $m = 100$ нулеви хипотези, Процедурата на Бонферони изисква да контролираме грешката тип I за всяка нулева хипотеза на ниво $0,1/100 = 0,001$, т.е. да се отхвърлят всички нулеви хипотези за чиято р-стойност е под 0,001.

Корекцията на Бонферони ни дава спокойствие, че не сме отхвърлили погрешно твърде много нулеви хипотези, но за цена: ние отхвърляме малко нулеви хипотези и по този начин обикновено правим доста грешки от тип II.

Корекцията на Бонферони е най-известната и най-често използваната корекция на множествеността в цялата статистика. Неговото разпространение се дължи до голяма степен на факта, че е много лесен за разбиране и лесен за прилагане, а също и от факта, че успешно контролира грешка от тип I, независимо дали m тестовите на хипотезата са независими. Въпреки това, обикновено не е нито най-мощният, нито най-добрият подход за корекция на множество тестове. По-специално, корекцията на Бонферони може да бъде доста консервативна, в смисъл, че истинският FWER често е доста по-нисък от номиналния (или целевия) FWER; това произтича от горното неравенство. За разлика от това, една по-малко консервативна процедура може да ни позволи да контролираме FWER, като същевременно отхвърляме повече нулеви хипотези и следователно правим по-малко грешки от тип II.

3.2.2. Процедурата на Холм за понижаване на степента

Методът на Холм, известен също като процедурата на Холм за понижаване на степента или методът на Холм - Холм, е алтернатива на процедурата Бонферони. Методът на Холм контролира FWER, но е по-малко консервативен от Бонферони, в смисъл, че ще отхвърли повече нулеви хипотези, което обикновено води до по-малко грешки от тип II и

следователно по-голяма мощност. Процедурата е обобщена в следния алгоритъм:

1. Specify α , the level at which to control the FWER.
2. Compute p -values, $p_1, \dots, p_m$, for the m null hypotheses $H_{01}, \dots, H_{0m}$.
3. Order the m p -values so that $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$.
4. Define

$$L = \min \left\{ j : p_{(j)} > \frac{\alpha}{m + 1 - j} \right\}.$$

5. Reject all null hypotheses H_{0j} for which $p_j < p_{(L)}$.

В процедурата на Холм, прагът, който използваме, за да отхвърлим всяка нулева хипотеза - $p_{(L)}$ в Стъпка 5 — всъщност зависи от стойностите на всички $\underline{m}$ от p -стойностите. Това е в контраст с процедурата на Бонферони, при която за контролиране на FWER на ниво α , ние отхвърляме всички нулеви хипотези, за които p -стойността е под α/m , независимо от другите p -стойности. Методът на Холм не прави предположения за независимост относно тестовете за $\underline{m}$ хипотези и е еднакво по-мощен от метода на Бонферони - той винаги ще отхвърли поне толкова нулеви хипотези, колкото Бонферони — и затова винаги трябва да бъде предпочитан.

4. Степен на фалшиви открития

4.1. Интуиция за степента на фалшиви открития

Когато $\underline{m}$ е голямо, тогава опитът да предотвратим всеки неверен положителен резултат (както при FWER контрол) е просто твърде строг. Вместо това можем да се опитаме да се уверим, че съотношението на фалшивите положителни резултати (V) към общите положителни резултати ($V + S = R$) е достатъчно ниско, така че повечето от отхвърлените нулеви хипотези да не са фалшиви положителни резултати. Съотношението V / R е известно като пропорцията на фалшивото откритие (false discovery proportion - FDP).

Искаме анализаторът на данни да може да контролира FDP: да се увери, че не повече от, да кажем, 20% от отхвърлените нулеви хипотези са фалшиви положителни резултати. Въпреки това, на практика, контролирането на FDP е невъзможна задача за анализатора на данни, тъй като тя няма начин да бъде сигурна за всеки конкретен набор от данни кои хипотези са верни и кои са грешни. Това е много подобно на факта, че анализаторът на данни може да контролира FWER, т.е. той може да гарантира, че $\Pr(V \geq 1) \leq \alpha$ за всяко предварително посочено α , но не може да гарантира, че $V = 0$ за всеки конкретен набор от данни (накратко да не успее да отхвърли никакви нулеви хипотези, т.е. задаване на $R = 0$).

Затова вместо да контролираме степента на фалшиво откриване (FDR), я дефинираме като $FDR = E(FDP) = E(V / R)$. Когато контролираме FDP на (да кажем) ниво $q = 20\%$, ние отхвърляме възможно най-много нулеви хипотези, като същевременно гарантираме, че средно не повече от 20% от тези отхвърлени нулеви хипотези са фалшиви положителни резултати.

В дефиницията на FDR като $FDR = E(FDP) = E(V/R)$ очакването е поето от популация, от която се генерират данните. Да предположим например, че контролираме FDR за m нулеви хипотези при $q = 0,2$. Това означава, че ако повторим този експеримент огромен брой пъти и всеки път контролираме FDR при $q = 0,2$, тогава трябва да очакваме, че средно 20% от отхвърлените нулеви хипотези ще бъдат фалшиво положителни. В даден набор от данни делът на фалшивите положителни резултати сред отхвърлените хипотези може да бъде по-голям или по-малък от 20%.

Досега сме мотивирали използването на FDR от прагматична гледна точка, като твърдим, че когато m е голямо, контролирането на FWER е просто твърде строго и няма да доведе до „достатъчно“ открития. Допълнителна мотивация за използването на FDR е, че той е в съответствие с начина, по който данните често се събират в съвременните приложения. Тъй като наборите от данни продължават да нарастват по размер в различни полета, все по-често се провеждат огромен брой тестове на хипотези за проучвателни, а не за потвърдителни цели.

За разлика от p -стойностите, за които има праг от 0,05 обикновено се разглежда като минимален стандарт на доказателство за „положителен“ резултат, а праг от 0,01 или дори 0,001 се разглежда като много по-убедителен, няма стандартно приет праг за контрол на FDR. Вместо това изборът на праг на FDR обикновено зависи от контекста или дори зависи от набора от данни.

4.2. Процедурата на Бенджамини-Хохберг

Сега да се съсредоточим върху задачата да контролираме FDR: тоест, решаваме кои нулеви хипотези да отхвърлим, като същевременно гарантираме, че FDR , $E(V/R)$, е по-малко или равно на някаква предварително определена стойност q . За да направим това, имаме нужда от някакъв начин да свържем p -стойностите, $p_1, \dots, p_m$, от m нулеви хипотези с желаната FDR стойност, q . Оказва се, че много проста процедура, описана в следния алгоритъм, може да се използва за управление на FDR:

1. Specify q , the level at which to control the FDR.
2. Compute p -values, $p_1, \dots, p_m$, for the m null hypotheses $H_{01}, \dots, H_{0m}$.
3. Order the m p -values so that $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$.
4. Define

$$L = \max\{j : p_{(j)} < qj/m\}.$$
5. Reject all null hypotheses H_{0j} for which $p_j \leq p_{(L)}$.

Този алгоритъм е известен като процедурата на Бенджамини-Хохберг. Основната процедура на този алгоритъм е в $L = \max\{j : p_{(j)} < qj/m\}$. Докато m p -стойностите са независими или само леко зависими,

тогава процедурата на Бенджамини-Хохберг гарантира, че $FDR \leq q$. С други думи, тази процедура гарантира, че средно не повече от част от q от отхвърлените нулеви хипотези са фалшиви положителни резултати. Забележително е, че това е валидно независимо от това колко нулеви хипотези са верни и независимо от разпределението на p -стойностите за нулевите хипотези, които са неверни. Следователно, процедурата на Бенджамини-Хохберг ни дава много лесен начин да определим, даден набор от m p -стойности, кои нулеви хипотези да отхвърлим, за да контролираме FDR на всяко предварително определено ниво q .

Има фундаментална разлика между процедурата Бонферони и процедурата на Бенджамини-Хохберг. В процедурата на Бонферони, за да контролираме $FWER$ за m нулеви хипотези на ниво α , трябва просто да отхвърлим нулеви хипотези, за които p -стойността е под α/m . Този праг на α/m не зависи от нищо относно данните (освен стойността на m) и със сигурност не зависи от самите p -стойности. За разлика от това, прагът на отхвърляне, използван в процедурата на Бенджамини-Хохберг, е по-сложен: ние отхвърляме всички нулеви хипотези, за които p -стойността е по-малка или равна на L -тата най-малка p -стойност, където L само по себе си е функция на всички m p -стойности. Следователно, когато провеждаме процедурата на Бенджамини-Хохберг, не можем да планираме предварително какъв праг ще използваме, за да отхвърлим p -стойностите; първо трябва да видим нашите данни. Например, абстрактно няма начин да разберем дали ще отхвърлим нулева хипотеза, съответстваща на p -стойност от 0,01 при използване на праг на FDR от 0,1 с $m = 100$; отговорът зависи от стойностите на останалите $m-1$ p -стойности. Това свойство на процедурата на Бенджамини-Хохберг се споделя от процедурата на Холм, която също включва зависим от данните праг на p -стойност.

5. Подход за повторно вземане на проби към p -стойности и коефициенти на фалшиви открития

Досега дискусията в тази глава предполагаше, че се интересуваме от тестване на конкретна нулева хипотеза H_0 , използвайки тестова статистика T , която има известно (или предполагаемо) разпределение под H_0 , като нормално разпределение, t -разпределение, χ^2 -разпределение или F -разпределение. Това се нарича теоретично нулево разпределение. Обикновено разчитаме на наличието на теоретично нулево разпределение, за да получим p -стойността, свързана с нашата тестова статистика. Наистина, за повечето типове нулеви хипотези, които може да ни е интересно да тестваме, е налично теоретично нулево разпределение, при условие че сме готови да направим строги предположения относно нашите данни. Въпреки това, ако нашата нулева хипотеза H_0 или тестова статистика T е донякъде необичайна, тогава може да се окаже, че няма налично теоретично нулево разпределение. Като алтернатива, дори ако съществува теоретично нулево разпределение, тогава ние може да внимава да разчита на него, може би защото е нарушено някакво предположение, което се изисква, за да се задържи. Например, може би размерът на извадката е твърде малък. В този раздел представяме рамка за извършване на извод в тази настройка, която използва наличието на бързи компютри, за да се приближи нулевото разпределение на T и по този начин да се получи p -стойност. Въпреки че

тази рамка е много обща, тя трябва да бъде внимателно създадена за конкретен проблем от интерес. Следователно в това, което следва, разглеждаме конкретен пример, в който искаме да проверим дали средните стойности на две случайни променливи са равни, като използваме двуизвадков t-тест.

5.1. Подход за повторно вземане на проби към р-стойността

Искаме да проверим дали средната стойност на случайна променлива X е равна на средната стойност на случайна променлива Y , т.е. $H_0: E(X) = E(Y)$, срещу алтернативата $H_a: E(X) \neq E(Y)$. При n_X независими наблюдения от X и n_Y независими наблюдения от Y t-статистиката на две извадки приема формата:

$$T = \frac{\hat{\mu}_X - \hat{\mu}_Y}{s \sqrt{\frac{1}{n_X} + \frac{1}{n_Y}}}$$

, където:

$$\hat{\mu}_X = \frac{1}{n_X} \sum_{i=1}^{n_X} x_i, \hat{\mu}_Y = \frac{1}{n_Y} \sum_{i=1}^{n_Y} y_i, s = \sqrt{\frac{(n_X-1)s_X^2 + (n_Y-1)s_Y^2}{n_X + n_Y - 2}},$$

и s_X^2 и s_Y^2 са безпристрастни оценки на дисперсиите в двете групи. Голяма (абсолютна) стойност на T предоставя доказателство срещу H_0 . Ако n_X и n_Y са големи, тогава T приблизително следва $N(0, 1)$ разпределение. Но ако n_X и n_Y са малки, тогава при липса на силни предположения за разпределението на X и Y , ние не знаем теоретичното нулево разпределение на T . В този случай се оказва, че можем да приближим нулевото разпределение на T , като използваме подход на повторно вземане на проби или по-конкретно подход на пермутация. За целта провеждаме мисловен експеримент. Ако H_0 е в сила, така че $E(X) = E(Y)$ и правим по-силното предположение, че разпределенията на X и Y са еднакви, тогава разпределението на T е инвариантно при размяна на наблюдения на X с наблюдения на Y . Тоест, ако сменим произволно някои от наблюденията в X с наблюденията в Y , тогава тестовата статистика T , изчислена въз основа на тези разменени данни, има същото разпределение като T въз основа на оригиналните данни. Това е вярно само ако H_0 е валидно и разпределенията на X и Y са еднакви.

За целта провеждаме мисловен експеримент. Ако H_0 е в сила, така че $E(X) = E(Y)$ и правим по-силното предположение, че разпределенията на X и Y са еднакви, тогава разпределението на T е инвариантно при размяна на наблюдения на X с наблюдения на Y . Тоест, ако разменим на случаен принцип някои от наблюденията в X с наблюденията в Y , тогава тестовата статистика T в (13.11), изчислена въз основа на тези разменени данни, има същото разпределение като T въз основа на оригиналните данни. Това е вярно само ако H_0 е валидно и разпределенията на X и Y са еднакви.

Това предполага, че за да се приближи нулевото разпределение на T , можем да приемем следния подход. Произволно пермутираме $n_X + n_Y$ наблюдения $\underline{V}$ пъти, за някаква голяма стойност на $\underline{V}$, и всеки път, когато изчисляваме T . Оставяме $T^*_1, \dots, T^*_V$ да означава стойностите на T върху пермутираните данни. Те могат да се разглеждат като приближение на нулевото разпределение на T под H_0 . По дефиниция р-стойността е вероятността за

наблюдение на тестова статистика поне в този екстремум под H_0 . Следователно, за да изчислим p -стойност за T , можем просто да изчислим частта от пермутирани набори от данни, за които стойността на тестовата статистика е поне толкова екстремна, колкото стойността, наблюдавана върху оригиналните данни:

$$p\text{-value} = \frac{\sum_{b=1}^B 1_{(|T^{*b}| \geq |T|)}}{B},$$

Тази процедура е обобщена в следния алгоритъм:

1. Compute T , defined in (13.11), on the original data $x_1, \dots, x_{n_X}$ and $y_1, \dots, y_{n_Y}$.
2. For $b = 1, \dots, B$, where B is a large number (e.g. $B = 10,000$):
 - (a) Permute the $n_X + n_Y$ observations at random. Call the first n_X permuted observations $x_1^*, \dots, x_{n_X}^*$, and call the remaining n_Y observations $y_1^*, \dots, y_{n_Y}^*$.
 - (b) Compute (13.11) on the permuted data $x_1^*, \dots, x_{n_X}^*$ and $y_1^*, \dots, y_{n_Y}^*$, and call the result T^{*b} .
3. The p -value is given by $\frac{\sum_{b=1}^B 1_{(|T^{*b}| \geq |T|)}}{B}$.

Като цяло, при настройки с по-малък размер на извадката или по-изкривено разпределение на данните (така че теоретичното нулево разпределение е по-малко точно), разликата между повторното вземане на проби и теоретичните p -стойности ще бъде по-ясно изразена.

5.2. Подход за повторно вземане на проби към коефициента на фалшиви открития

Сега да предположим, че искаме да контролираме FDR за m нулеви хипотези, $H_{01}, \dots, H_{0m}$, в настройка, в която или няма теоретично нулево разпределение е налично или просто предпочитаме да избягваме използването на теоретично нулево разпределение. Ние използваме t -статистика с две извадки за всяка хипотеза, водеща до тестовата статистика $T_1, \dots, T_m$. Можем просто да изчислим p -стойност за всяка от m нулеви хипотези и след това да приложим процедурата на Бенджамини-Хохберг към тези p -стойности. Оказва се обаче, че можем да направим това по по-директен начин, без дори да е необходимо да изчисляваме p -стойности. Казахме, че FDR се дефинира като $E(V/R)$, използвайки нотацията в таблицата:

	H_0 is True	H_0 is False	Total
Reject H_0	V	S	R
Do Not Reject H_0	U	W	$m - R$
Total	m_0	$m - m_0$	m

За да оценим FDR чрез повторно вземане на проби, първо правим следното приближение:

$$\text{FDR} = E \left(\frac{V}{R} \right) \approx \frac{E(V)}{R}.$$

Сега да предположим, че отхвърляме всяка нулева хипотеза, за която тестовата статистика надвишава c по абсолютна стойност. Тогава изчисляването на R в знаменателя от дясната страна на горното приближение е лесно:

$$R = \sum_{j=1}^m 1(|T_j| \geq c).$$

Но числителят $E(V)$ от дясната страна на горното приближение е повече предизвикателен. Това е очакваният брой фалшиви положителни резултати, свързани с отхвърлянето на всяка нулева хипотеза, за която тестовата статистика надвишава c по абсолютна стойност. Оценяването на V е предизвикателство, защото не знаем кои от $H_{01}, \dots, H_{0m}$ са наистина верни и затова не знаем кои отхвърлени хипотези са фалшиви положителни. За да преодолеем този проблем, ние използваме подход за повторно вземане на проби, при който симулираме данни под $H_{01}, \dots, H_{0m}$ и след това изчисляваме получената тестова статистика. Броят на повторно взетите тестови статистики, които надвишават c , осигурява оценка на V .

По-подробно, в случай на двуизвадкова t -статистика за всеки на нулевите хипотези $H_{01}, \dots, H_{0m}$, можем да оценим $E(V)$ както следва. Нека $x^{(j)}_1, \dots, x^{(j)}_{nX}$ и $y^{(j)}_1, \dots, y^{(j)}_{nY}$ означават данните, свързани с j -тата нулева хипотеза, $j = 1, \dots, m$. Ние пермутираме тези $nX + nY$ наблюдения на случаен принцип и след това изчисляваме t -статистиката върху пермутираните данни. За тези пермутирани данни знаем, че всички нулеви хипотези $H_{01}, \dots, H_{0m}$ са валидни; следователно, броят на пермутираните t -статистики, които надвишават прага c по абсолютна стойност, предоставя оценка за $E(V)$. Тази оценка може да бъде допълнително подобрена чрез повтаряне на процеса на пермутация B пъти за голяма стойност на B и осредняване на резултатите.

Следният алгоритъм описва подробно тази процедура. Той предоставя това, което е известно като добавена оценка на FDR, тъй като горното приближение ни позволява да оценим FDR, като включим R в знаменателя и оценка за $E(V)$ в числителя:

1. Select a threshold c , where $c > 0$.
2. For $j = 1, \dots, m$:
 - (a) Compute $T^{(j)}$, the two-sample t -statistic (13.11) for the null hypothesis H_{0j} on the basis of the original data, $x_1^{(j)}, \dots, x_{n_X}^{(j)}$ and $y_1^{(j)}, \dots, y_{n_Y}^{(j)}$.
 - (b) For $b = 1, \dots, B$, where B is a large number (e.g. $B = 10,000$):
 - i. Permute the $n_X + n_Y$ observations at random. Call the first n_X observations $x_1^{*(j)}, \dots, x_{n_X}^{*(j)}$, and call the remaining observations $y_1^{*(j)}, \dots, y_{n_Y}^{*(j)}$.
 - ii. Compute (13.11) on the permuted data $x_1^{*(j)}, \dots, x_{n_X}^{*(j)}$ and $y_1^{*(j)}, \dots, y_{n_Y}^{*(j)}$, and call the result $T^{(j),*b}$.
3. Compute $R = \sum_{j=1}^m 1_{(|T^{(j)}| \geq c)}$.
4. Compute $\hat{V} = \frac{\sum_{b=1}^B \sum_{j=1}^m 1_{(|T^{(j),*b}| \geq c)}}{B}$.
5. The estimated FDR associated with the threshold c is $\hat{V}/R$.

Започнахме този раздел, като отбелязахме, че за да контролираме FDR за m тестове на хипотези, използвайки подход за повторно вземане на проби, бихме могли просто да изчислим m р-стойности за повторно вземане на проби и след това да приложим процедурата на Бенджамини-Хохберг към тези р-стойности. Оказва се, че ако дефинираме р-стойността на j -то повторно вземане на проби като:

$$p_j = \frac{\sum_{j'=1}^m \sum_{b=1}^B 1_{(|T_{j'}^{*b}| \geq |T_j|)}}{Bm}$$

за $j = 1, \dots, m$, след това прилагане на процедурата на Бенджамини-Хохберг за тези повторно взети проби р-стойности е точно еквивалентна на алгоритъма. Това е алтернатива, която обединява информацията във всички m теста на хипотези за приближаване на нулевото разпределение.

5.3. Кога са полезни подходите за повторно вземане на проби ?

В предните два раздела обмислихме тестване на нулеви хипотези от формата $H_0 : E(X) = E(Y)$, използвайки t -статистика с две извадки, за която апроксимирахме нулевото разпределение чрез подход за повторно вземане на проби. Видяхме, че използването на подхода за повторно вземане на проби ни даде съществено различни резултати от използването на подхода на теоретичната р-стойност. Като цяло има две настройки, при които използването на подхода за повторно вземане на проби е особено полезен:

1. Може би не е налично теоретично нулево разпределение. Това може да е случай, ако тествете необичайна нулева хипотеза H_0 или използвате необичайна тестова статистика T .
2. Може би е налично теоретично нулево разпределение, но предположенията, необходими за неговата валидност, не са валидни. Например t -статистиката за две извадки следва $t_{nX+nY-2}$ разпределение само ако наблюденията са нормално разпределени. Освен това следва $N(0, 1)$ разпределение само ако nX и nY са доста големи. Ако данните са ненормално и nX и nY са малки, тогава p -стойности, които са полезни на теоретичното нулево разпределение няма да са валидни (т.е. те няма да контролират правилно грешката от тип I).

Като цяло, ако можем да измислим начин за повторна проба или пермутация на нашите наблюдения, за да генерираме данни, които следват нулевото разпределение, тогава можете да изчислим p -стойности или да оценим FDR, като използваме варианти на последните два алгоритъма. В много настройки от реалния свят това осигурява мощен инструмент за тестване на хипотези, когато няма готови тестове за хипотези налични, или когато ключовите допускания в основата на тези готови тестове са нарушени.

6. Заключение

Множествените тестове в статистиката са важен инструмент за справяне с проблема на множествените сравнения, който възниква при изпълнението на множество статистически тестове. Те помагат да се коригира нивото на значимост, за да се компенсира за броя на тестовете и да се намали вероятността за грешка при отхвърляне на вярната нулева хипотеза. Използването на множествени тестове е важно за гарантиране на точността и надеждността на статистическите изводи, особено когато се извършват множество сравнения или тестове. Въпреки че те могат да намалят вероятността за грешка от първи род (отхвърляне на вярната нулева хипотеза), трябва да се има предвид, че те могат да направят тестовете по-консервативни и да намалят чувствителността към откриване на реални ефекти. По този начин, множествените тестове трябва да бъдат използвани с разбиране и внимание към конкретния контекст и целите на изследването.